

Kaspar 2028

Supervised by Prof. Dr. Lena Gieseke

K.ai: Entwurf Architektur

Isolierte Lokal-Benchmarks / NVIDIA GeForce RTX 4090 (24GB)

LLM Benchmarking Setup

Alle Benchmarks wurden innerhalb der folgenden Rahmen-Parameter durchgeführt

- Single GPU → NVIDIA GeForce RTX 4090 (24 GB)
- OS → WSL (Ubuntu Distro)
- Python Environment Management → uv
- Referenz-Datensatz: FreedomIntelligence/sharegpt-deutsch

Time to First Token (TTFT)

N = 10 queries	vLLM	SGLang
Mean TTFT (ms)	125.68	66.53
Median TTFT (ms)	84.61	70.08
P99 TTFT (ms)	427.94*	84.02

N = 6200 queries	vLLM	SGLang
Mean TTFT (ms)	34.57	48.74
Median TTFT (ms)	29.84	42.73
P99 TTFT (ms)	79.27	153.23

Time per Output Token (TPOT)

N = 10 queries	vLLM	SGLang
Mean TPOT (ms)	14.30	12.19
Median TPOT (ms)	14.27	12.23
P99 TPOT (ms)	14.45	12.27

N = 6200 queries	vLLM	SGLang
Mean TPOT (ms)	14.32	12.17
Median TPOT (ms)	14.00	12.11
P99 TPOT (ms)	20.80	12.85

Ergebnisse

- TTFT ausschlaggebend für K.ai (Latenzminimierung)
 - Fokus auf N = 6200 Anfragen
 - ggf. Fehler bei der Messung mit N = 10 [*Ausreißer auf Folie 3]
 - entspricht längerer Laufzeit dh. fakturiert ggf. Ermüdungserscheinungen durch Temperaturentwicklung mit ein
- Durchsatz (TPOT) zwar ~ 6 ms schneller bei SGLang
- ABER erstes Token (Begin der Antwort) ~ 52 ms schneller bei vLLM