Kaspar 2028
Betreut durch Prof. Dr. Lena Gieseke

K.ai: HPI KI-Sprechstunde

Speech-to-Speech: Zwischenstand Architektur & Fragen

Ziele

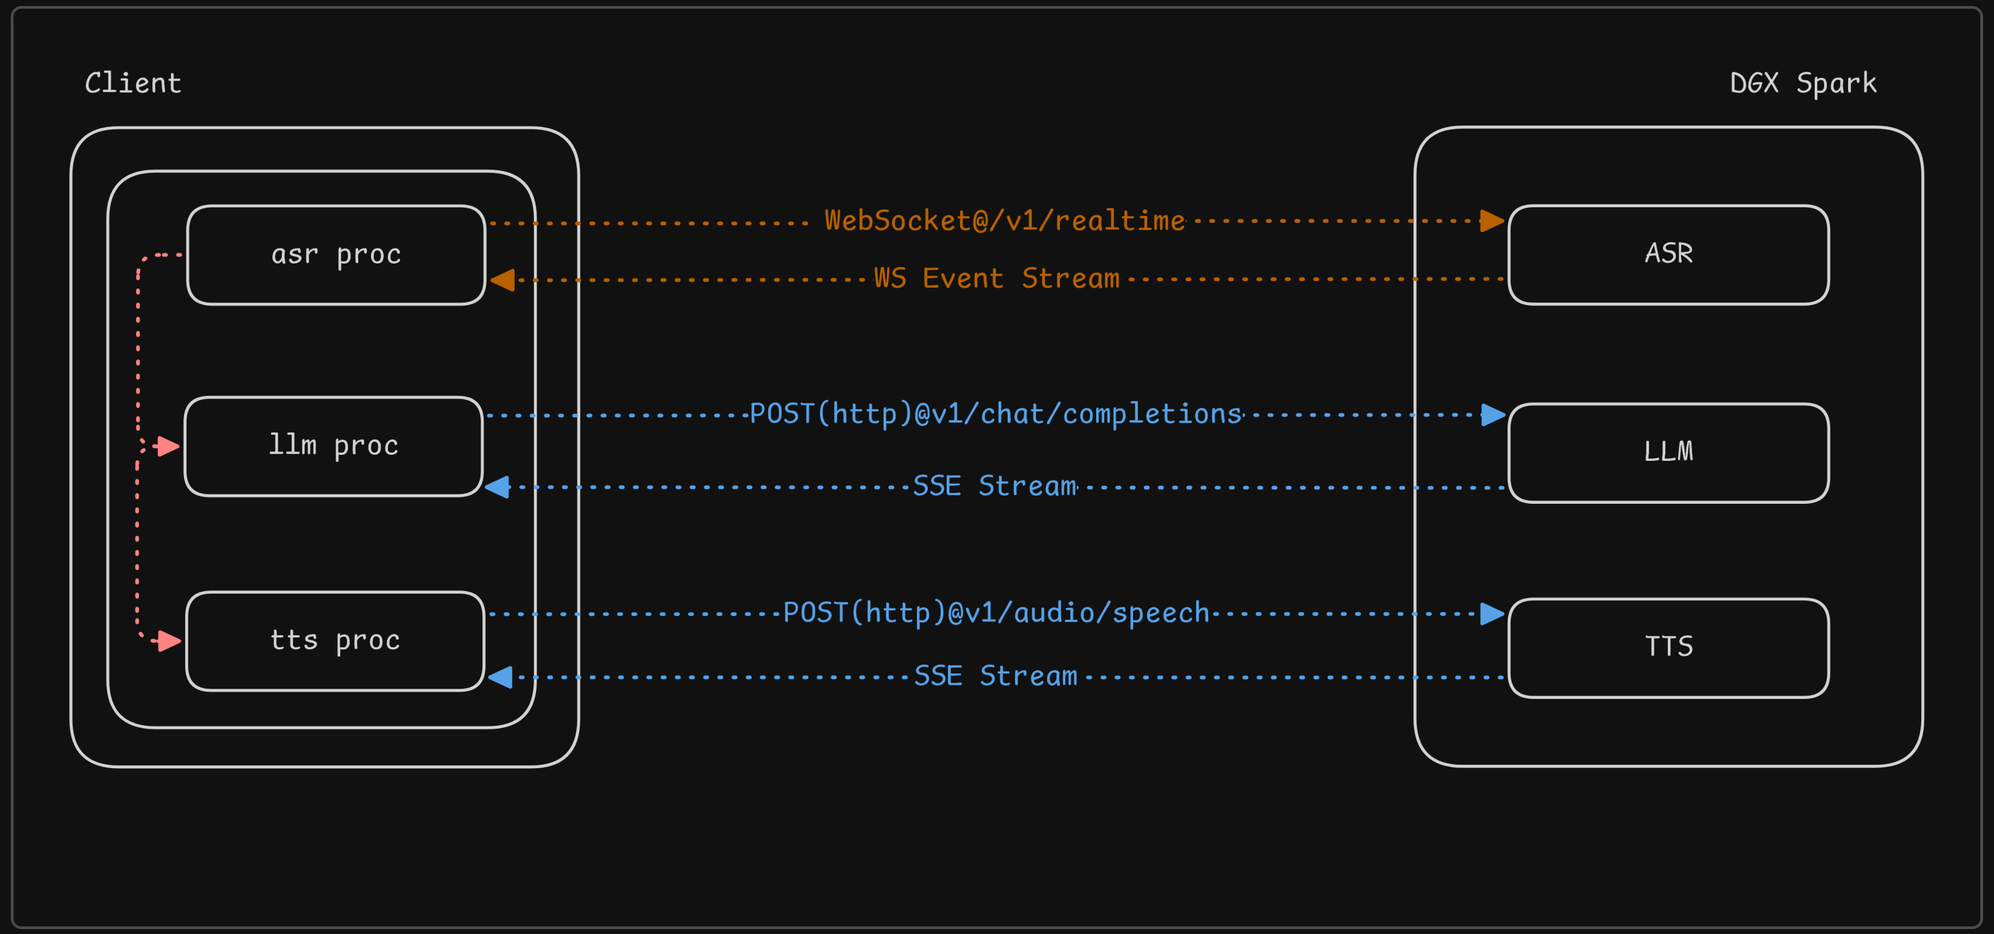
`Primär`

- E2E-Latenz innerhalb natürlicher Sprachgeschwindigkeit (> 500 ms)
- hohe inhaltliche & klangliche Qualität

`Sekundär`

- Lokale, selbst gehostete Infrastruktur

Architektur



Hardware

`NVIDIA DGX Spark (MSI EdgeXpert)`

- 128 GB Unified Memory (LPDDR5x, 256-bit interface, 4266 MHz, 273 GB/s)
- 20-core Arm CPU

Software

Server: vLLM (OpenAI Compatible)

`kai-asr`	vllm-openai:v0.33.0 / mistralai/Voxtral-Mini-4B-Realtime-2602
`kai-llm`	vllm-openai:v0.33.0 / nvidia/gemma-4-26B-A4B-NVFP4
`kai-tts`	vllm-omni:v0.32.0 / openbmb/VoxCPM2

Client: Custom (based on hf: speech-to-speech)

Fragen

- Grundsätzliche Widersprüche, offensichtliche Probleme oder sonstige Anmerkungen?
- Vorschläge für alternative / besser geeignete einzelne Komponenten?
- VAD, womit am besten anfangen?
  - ML-basiert vs. naive Implementierungen (z. B. energiebasiert)?
  - Lösungen für Selbstunterbrechung (z. B. durch Interferenz/NC)?
  - Unterbrechen der User